

第13讲: 2D运动估计方法-差分法

- 差分法: **Lukas-Kanade**

- 一般解决方案: 参数运动
- 特殊情况: 位移估计

- 差分法: **Horn-Schunk**

- 全局平滑
- 方向性平滑


- 像素递归运动估计

- 贝叶斯运动估计

- 问题描述
- 非线性优化

稠密运动估计

- 估计每个**像素（或超像素）**的运动矢量（MV）。



“Foreman”
序列的稠密运
动场

Lukas-Kanade: 特殊情况

- **位移估计**: 定义像素 \mathbf{x} 处的光流公式中的误差作为增量位移矢量 $\Delta\mathbf{p} = (\Delta d_1, \Delta d_2)$ 的函数:

$$e_o(\mathbf{x}, \Delta\mathbf{p}) = \frac{\partial s_c(\mathbf{x}, t)}{\partial x_1} \Delta d_1 + \frac{\partial s_c(\mathbf{x}, t)}{\partial x_2} \Delta d_2 + \frac{\partial s_c(\mathbf{x}, t)}{\partial t} \Delta t$$

- 在块 \mathbf{B} 内的所有像素 \mathbf{x} 处, 误差 $e_o(\mathbf{x}, \Delta\mathbf{p})$ 通常并不恰好为零, 因为可能有:
 - i) 从离散图像样本估计偏微分的误差,
 - ii) 块 \mathbf{B} 内的多个运动,
 - iii) 帧到帧的强度变化。
- 像素块 \mathbf{B} 上的总平方误差由 $e_o(\mathbf{x}, \Delta\mathbf{p})$ 的平方和给出, 可以表示为:

$$E_o(\Delta\mathbf{p}) = \sum_{\mathbf{x} \in \mathbf{B}} \left[\frac{\partial s_c(\mathbf{x}, t)}{\partial x_1} \Delta d_1 + \frac{\partial s_c(\mathbf{x}, t)}{\partial x_2} \Delta d_2 + \frac{\partial s_c(\mathbf{x}, t)}{\partial t} \Delta t \right]^2$$

Lukas-Kanade: 特殊情况

- 我们通过计算关于未知数 Δd_1 和 Δd_2 的偏微分对 $E_o(\Delta p)$ 进行最小化。

$$\frac{\partial E_o(\Delta p)}{\partial \Delta d_i} = 2 \sum_{\mathbf{x} \in B} \left[\frac{\partial s_c(\mathbf{x}, t)}{\partial x_1} \Delta d_1 + \frac{\partial s_c(\mathbf{x}, t)}{\partial x_2} \Delta d_2 + \frac{\partial s_c(\mathbf{x}, t)}{\partial t} \Delta t \right] \frac{\partial s_c(\mathbf{x}, t)}{\partial x_i} = 0$$

- 同时解这两个方程，则有：

$$\begin{aligned} \sum_{\mathbf{x} \in B} \left[\frac{\partial s_c(\mathbf{x}, t)}{\partial x_1} \right]^2 \Delta d_1 + \sum_{\mathbf{x} \in B} \left[\frac{\partial s_c(\mathbf{x}, t)}{\partial x_1} \right] \left[\frac{\partial s_c(\mathbf{x}, t)}{\partial x_2} \right] \Delta d_2 &= - \sum_{\mathbf{x} \in B} \left[\frac{\partial s_c(\mathbf{x}, t)}{\partial t} \right] \left[\frac{\partial s_c(\mathbf{x}, t)}{\partial x_1} \right] \Delta t \\ \sum_{\mathbf{x} \in B} \left[\frac{\partial s_c(\mathbf{x}, t)}{\partial x_1} \right] \left[\frac{\partial s_c(\mathbf{x}, t)}{\partial x_2} \right] \Delta d_1 + \sum_{\mathbf{x} \in B} \left[\frac{\partial s_c(\mathbf{x}, t)}{\partial x_2} \right]^2 \Delta d_2 &= - \sum_{\mathbf{x} \in B} \left[\frac{\partial s_c(\mathbf{x}, t)}{\partial t} \right] \left[\frac{\partial s_c(\mathbf{x}, t)}{\partial x_2} \right] \Delta t \end{aligned}$$

可以以**矢量矩阵形式**（通过归一化 $\Delta t=1$ ）写成：

$$\mathbf{H} \Delta \mathbf{p} = \mathbf{b}$$

其中：

$$\mathbf{H} = \begin{bmatrix} \sum_{\mathbf{x} \in B} \left[\frac{\partial s_c(\mathbf{x}, t)}{\partial x_1} \right]^2 & \sum_{\mathbf{x} \in B} \left[\frac{\partial s_c(\mathbf{x}, t)}{\partial x_1} \right] \left[\frac{\partial s_c(\mathbf{x}, t)}{\partial x_2} \right] \\ \sum_{\mathbf{x} \in B} \left[\frac{\partial s_c(\mathbf{x}, t)}{\partial x_1} \right] \left[\frac{\partial s_c(\mathbf{x}, t)}{\partial x_2} \right] & \sum_{\mathbf{x} \in B} \left[\frac{\partial s_c(\mathbf{x}, t)}{\partial x_2} \right]^2 \end{bmatrix} \quad \mathbf{b} = \begin{bmatrix} -\sum_{\mathbf{x} \in B} \left[\frac{\partial s_c(\mathbf{x}, t)}{\partial t} \right] \left[\frac{\partial s_c(\mathbf{x}, t)}{\partial x_1} \right] \\ -\sum_{\mathbf{x} \in B} \left[\frac{\partial s_c(\mathbf{x}, t)}{\partial t} \right] \left[\frac{\partial s_c(\mathbf{x}, t)}{\partial x_2} \right] \end{bmatrix}$$

Lukas-Kanade: 特殊情况

- 然后，可以从中计算**增量参数向量**的估计：

$$\Delta \mathbf{p} = \mathbf{H}^{-1} \mathbf{b}$$

- 如果在块B内存在足够的强度变化，且矩阵H可逆，即秩为2，则有唯一解。
- 该解是 $N \times N$ 个光流方程的**最小二乘解**，块B内的每个像素都有一个具有相同的两个未知数的方程。

Lukas-Kanade 问题描述

- **一般情况 – 扭曲参数的估计：** 我们最小化当前帧向前一帧扭曲的误差，由下式给出：

$$\sum_{\mathbf{x} \in B} [s_k(\mathbf{x}') - s_{k-1}(\mathbf{x})]^2$$

其中 B 表示 $N \times N$ 的具有**足够灰度等级变化**的像素块，

$\mathbf{x}' = T(\mathbf{x}; \mathbf{p}) = [T_1(\mathbf{x}; \mathbf{p}) \ T_2(\mathbf{x}; \mathbf{p})]^T$ 表示作为模型参数矢量 \mathbf{p} 的参数运动模型。

- 这是一个**非线性优化问题**，可以在假定小运动的情况下通过使用泰勒级数展开替代 $s_k(\mathbf{x}')$ 的二次代价函数进行近似。
- 为了确保运动较小，我们**假设参数矢量 \mathbf{p} 的当前估计**是可用的，并且考虑由于增量参数更新 $\Delta \mathbf{p}$ 导致的差分运动的估计；即我们将其中 $\mathbf{x}' = T(\mathbf{x}; \mathbf{p} + \Delta \mathbf{p})$ 的 $s_k(\mathbf{x}')$ 扩展成关于点 $T(\mathbf{x}; \mathbf{p})$ 的泰勒级数。

Lukas-Kanade (cont'd)

- 关于 $\Delta \mathbf{p}$ 的二次代价函数由下式给出:

$$\sum_{\mathbf{x}} \left[s_k(\mathbf{T}(\mathbf{x}; \mathbf{p})) + \nabla s_k(\mathbf{T}(\mathbf{x}; \mathbf{p})) \frac{\partial \mathbf{T}}{\partial \mathbf{p}} \Delta \mathbf{p} - s_{k-1}(\mathbf{x}) \right]^2$$

其中项 $\frac{\partial \mathbf{T}}{\partial \mathbf{p}}$ 是参数模型的雅可比矩阵。基于 $\Delta \mathbf{p}$ 对上式最小化是最小二乘估计问题，有闭合形式解。

- 关于 $\Delta \mathbf{p}$ 计算偏微分，并令其为0：

$$2 \sum_{\mathbf{x}} \left[\nabla s_k(\mathbf{T}(\mathbf{x}; \mathbf{p})) \frac{\partial \mathbf{T}}{\partial \mathbf{p}} \right]^T \left[s_k(\mathbf{T}(\mathbf{x}; \mathbf{p})) + \nabla s_k(\mathbf{T}(\mathbf{x}; \mathbf{p})) \frac{\partial \mathbf{T}}{\partial \mathbf{p}} \Delta \mathbf{p} - s_{k-1}(\mathbf{x}) \right] = 0$$

- 求解 $\Delta \mathbf{p}$, 可得:

$$\Delta \mathbf{p} = \mathbf{H}^{-1} \sum_{\mathbf{x}} \left[\nabla s_k(\mathbf{T}(\mathbf{x}; \mathbf{p})) \frac{\partial \mathbf{T}}{\partial \mathbf{p}} \right]^T [s_{k-1}(\mathbf{x}) - s_k(\mathbf{T}(\mathbf{x}; \mathbf{p}))]$$

其中Hessian 阵为:

$$\mathbf{H} = \sum_{\mathbf{x}} \left[\nabla s_k(\mathbf{T}(\mathbf{x}; \mathbf{p})) \frac{\partial \mathbf{T}}{\partial \mathbf{p}} \right]^T \left[\nabla s_k(\mathbf{T}(\mathbf{x}; \mathbf{p})) \frac{\partial \mathbf{T}}{\partial \mathbf{p}} \right]$$

Lukas-Kanade (cont'd)

分层迭代求精过程可以概括为：

- 1) 在**最低分辨率估计帧** $s_k(\mathbf{x})$ 上求取空间/时间图像偏微分。注意，在每个分辨率级别只估计一次偏微分。设置初始参数向量 $\mathbf{p} = 0$ 。
- 2) 使用当前估计 \mathbf{p} ，将 $s_k(\mathbf{x})$ 中当前块向 $s_{k-1}(\mathbf{x})$ 相应块做**补偿（扭曲）**，以获得 $s_k(\mathbf{T}(\mathbf{x}; \mathbf{p}))$ ，可使用子像素运动补偿估计 $\Delta\mathbf{p}$ 。
- 3) **更新** $\mathbf{p} = \mathbf{p} + \Delta\mathbf{p}$ 。重复步骤2和3次。
- 4) 继续到下一个分辨率级别，直到我们达到金字塔中的**最高分辨率级别**。在每个分辨率级别，**缩放当前的参数向量** \mathbf{p} ，估计帧 $s_k(\mathbf{x})$ 上的空间/时间图像偏微分并转到步骤2。
- 5) 在最高分辨率级别，重复步骤2和3，直到**残差参数更新** $\Delta\mathbf{p}$ **收敛为零**。

逐层细化

- 克服孔径问题

- 针对低分辨率级别的大图像区域估计粗略的MV
- 在较高分辨率级别对较小图像区域连续细化
- 例如， 64×64 块在连续的较低分辨率级别以 32×32 ， 16×16 和 8×8 形式出现。因此，在最低级别的 8×8 MV分别在更高分辨率级别被细化为4个 8×8 MV，16个 8×8 MV和64个 8×8 MV。

- 缺点：可能漏掉快速移动的小对象。

Horn-Schunk法

- 假设空间和时间坐标是连续变量，运动估计被可写成**变分形式的优化问题**：

$$\hat{\mathbf{v}}(\mathbf{x}) = \arg \min_{\mathbf{v}(\mathbf{x})} \{E(\mathbf{v}(\mathbf{x}))\},$$

其中：

$$E(\mathbf{v}(\mathbf{x})) = \int_B \left(E_{\text{of}}^2(\mathbf{v}(\mathbf{x})) + \alpha^2 E_s^2(\mathbf{v}(\mathbf{x})) \right) d\mathbf{x}$$

B 表示**连续图像支撑区域**，而

$$E_{\text{of}}(\mathbf{v}(\mathbf{x})) = \langle \nabla s_c(\mathbf{x}, t), \mathbf{v}(\mathbf{x}) \rangle + \frac{\partial s_c(\mathbf{x}, t)}{\partial t}$$

是光流方程中的误差，施加了**数据一致性**。

- 第二项 $E_s(\mathbf{v}(\mathbf{x}))$ 是**平滑先验项**，其中速度矢量的空间变化可以通过速度矢量分量的**空间梯度的幅度平方和**来量化，由下式给出：

$$\begin{aligned} E_s^2(\mathbf{v}(\mathbf{x})) &= \|\nabla \mathbf{v}_1(\mathbf{x})\|^2 + \|\nabla \mathbf{v}_2(\mathbf{x})\|^2 \\ &= \left(\frac{\partial \mathbf{v}_1(\mathbf{x})}{\partial x_1} \right)^2 + \left(\frac{\partial \mathbf{v}_1(\mathbf{x})}{\partial x_2} \right)^2 + \left(\frac{\partial \mathbf{v}_2(\mathbf{x})}{\partial x_1} \right)^2 + \left(\frac{\partial \mathbf{v}_2(\mathbf{x})}{\partial x_2} \right)^2 \end{aligned}$$

Horn-Schunk (cont'd)

- 运动场越平滑，则 $E_s^2(\mathbf{v}(\mathbf{x}))$ 越小。而参数 α^2 的值越大，**平滑约束的影响** 越大。

- 对 $E(\mathbf{v}(\mathbf{x}))$ 求关于 v_1 和 v_2 的**偏微分**，并**令其为0**，可得：

$$\left[\alpha^2 + \left(\frac{\partial s_c}{\partial x_1} \right)^2 \right] v_1 + \frac{\partial s_c}{\partial x_1} \frac{\partial s_c}{\partial x_2} v_2 = \alpha^2 \bar{v}_1 - \frac{\partial s_c}{\partial x_1} \frac{\partial s_c}{\partial t}$$

$$\frac{\partial s_c}{\partial x_1} \frac{\partial s_c}{\partial x_2} v_1 + \left[\alpha^2 + \left(\frac{\partial s_c}{\partial x_2} \right)^2 \right] v_2 = \alpha^2 \bar{v}_2 - \frac{\partial s_c}{\partial x_2} \frac{\partial s_c}{\partial t}$$

\bar{v} 表示对像素邻域（不包括当前像素）求平均。

- 以上方程关于 v_1, v_2 为线性方程，可**迭代求出**：

$$\hat{v}_1^{(n+1)}(\mathbf{x}) = \bar{v}_1^{(n)}(\mathbf{x}) - \frac{\frac{\partial s_c}{\partial x_1} \bar{v}_1^{(n)}(\mathbf{x}) + \frac{\partial s_c}{\partial x_2} \bar{v}_2^{(n)}(\mathbf{x}) + \frac{\partial s_c}{\partial t}}{\alpha^2 + \left(\frac{\partial s_c}{\partial x_1} \right)^2 + \left(\frac{\partial s_c}{\partial x_2} \right)^2}$$

$$\hat{v}_2^{(n+1)}(\mathbf{x}) = \bar{v}_2^{(n)}(\mathbf{x}) - \frac{\frac{\partial s_c}{\partial x_1} \bar{v}_1^{(n)}(\mathbf{x}) + \frac{\partial s_c}{\partial x_2} \bar{v}_2^{(n)}(\mathbf{x}) + \frac{\partial s_c}{\partial t}}{\alpha^2 + \left(\frac{\partial s_c}{\partial x_1} \right)^2 + \left(\frac{\partial s_c}{\partial x_2} \right)^2}$$

Horn-Schunck (cont'd)

- 速度 $v_1^{(0)}(\mathbf{x}, t)$ 和 $v_2^{(0)}(\mathbf{x}, t)$ 的**初始估计通常设置为零**，并且从观察图像估计所有的空间和时间微分。空间图像偏微分可以通过高斯滤波器的微分来估计。
- Horn-Schunck通过**平均四个有限差分**来估计空间和时间微分，其中时间微分是从两帧估计的。

$$\frac{\partial s_c(x_1, x_2, t)}{\partial t} \approx \frac{1}{4} \{s[n_1, n_2, k+1] - s[n_1, n_2, k] + s[n_1+1, n_2, k+1] - s[n_1+1, n_2, k] + s[n_1, n_2+1, k+1] - s[n_1, n_2+1, k] + s[n_1+1, n_2+1, k+1] - s[n_1+1, n_2+1, k]\}$$

- Horn-Schunck方法在整个图像上或在所选窗口上**全局地施加光流和平滑约束**，这会导致：
 - 全局平滑度约束模糊“运动边缘”。
 - 在遮挡区域内施加光流约束。

自适应平滑约束

- **方向性平滑约束**可以表示为:

$$E_{ds}^2(\mathbf{v}(\mathbf{x})) = (\nabla \mathbf{v}_1)^T \mathbf{W} (\nabla \mathbf{v}_1) + (\nabla \mathbf{v}_2)^T \mathbf{W} (\nabla \mathbf{v}_2)$$

其中 \mathbf{W} 为**惩罚运动场变化的权重矩阵**，而运动场变化又依赖于视频灰度等级的空间变化。例如，权重矩阵 \mathbf{W} 可选择为：


$$\mathbf{W} = \frac{\mathbf{F} + \delta \mathbf{I}}{\text{trace}(\mathbf{F} + \delta \mathbf{I})}$$

其中 \mathbf{I} 为单位阵，用来保证在**空域不变区域使权重值非零**， δ 与 b^2 为全局标量常数，而：

$$\mathbf{F} = \begin{bmatrix} \left(\frac{\partial s_c}{\partial x_1}\right)^2 + b^2 \left\{ \left(\frac{\partial^2 s_c}{\partial x_1^2}\right)^2 + \left(\frac{\partial^2 s_c}{\partial x_1 \partial x_2}\right)^2 \right\} & \frac{\partial s_c}{\partial x_1} \frac{\partial s_c}{\partial x_2} + b^2 \left\{ \frac{\partial^2 s_c}{\partial x_1 \partial x_2} \left(\frac{\partial^2 s_c}{\partial x_1^2}\right)^2 + \left(\frac{\partial^2 s_c}{\partial x_1 \partial x_2}\right)^2 \right\} \\ \frac{\partial s_c}{\partial x_1} \frac{\partial s_c}{\partial x_2} + b^2 \left\{ \frac{\partial^2 s_c}{\partial x_1 \partial x_2} \left(\frac{\partial^2 s_c}{\partial x_1^2}\right)^2 + \left(\frac{\partial^2 s_c}{\partial x_1 \partial x_2}\right)^2 \right\} & \left(\frac{\partial s_c}{\partial x_2}\right)^2 + b^2 \left\{ \left(\frac{\partial^2 s_c}{\partial x_2^2}\right)^2 + \left(\frac{\partial^2 s_c}{\partial x_1 \partial x_2}\right)^2 \right\} \end{bmatrix}^{-1}$$

- 可观察到 **Horn-Schunck 方法**为上式的一种**特殊情况**，即：
 $\delta = 1$ ， $\mathbf{F} = \mathbf{0}$.

梯度下降法



像素递归运动估计

- **Netravali-Robbins 算法** [Rob 83] 最小化每个像素处的 DFD 的平方，由下式给出：

$$E(\mathbf{x}, \mathbf{d}) = [\text{DFD}(\mathbf{x}, \mathbf{d})]^2$$

其中 $\text{DFD}(\cdot)$ 表示位移的帧差。

- 通过 **最速下降法** 使在像素 \mathbf{x} 处的关于 \mathbf{d} 对 $E(\mathbf{x}, \mathbf{d})$ 进行最小化，迭代公式：

$$\hat{\mathbf{d}}^{(i+1)}(\mathbf{x}) = \hat{\mathbf{d}}^{(i)}(\mathbf{x}) - \varepsilon \text{DFD}(\mathbf{x}, \hat{\mathbf{d}}^{(i)}) \nabla_{\mathbf{x}} s_c(\mathbf{x} - \hat{\mathbf{d}}^{(i)}; t - \Delta t)$$

其中 $\nabla_{\mathbf{x}}$ 是相对于 \mathbf{x} 的梯度， ε 是步长。

- **初始估计** $\hat{\mathbf{d}}^{(0)}$ \mathbf{x} 可选先前像素的运动矢量 (MV) 或邻域中先前计算的 MV 的线性组合作为当前像素的 MV。
- 注意，梯度的 **负值指向最陡下降的方向**。

像素递归运动估计 (cont'd)

- **孔径问题**在像素递归方法中是显而易见的。由于更新项是沿着图像强度的空间梯度的向量，因此不能在与梯度向量垂直的方向上进行校正。
- Netravali-Robbins算法的**收敛速率**取决于**步长参数 ϵ 的选择**。例如，如果 $\epsilon = 1/16$ ，则需要至少32次迭代来估计2个像素的位移。另一方面，大步长的选择可能导致振荡行为。
- 为了促进更快的收敛，可使用**自适应步长**：

$$\epsilon = \frac{1}{\|\nabla_x s_c(\mathbf{x} - \hat{\mathbf{d}}^{(i)}; t - \Delta t)\|^2 + c^2}$$

其中偏置项 c^2 用来避免在空间梯度几乎为零的恒定强度的区域中除以零。

贝叶斯运动估计

- 贝叶斯运动估计的 **目标** 是对运动场的 **后验概率密度函数** $p(\mathbf{d}_1, \mathbf{d}_2 | \mathbf{s}_k, \mathbf{s}_{k-1})$ 进行 **最大化**，其中 $\mathbf{d}_1, \mathbf{d}_2$ 表示在给定观察数据（即两幅图像 \mathbf{s}_k 和 \mathbf{s}_{k-1} ）条件下每个像素上MV的两个分量，以字典顺序排列。
- 根据 **贝叶斯准则**：

$$p(\mathbf{d}_1, \mathbf{d}_2 | \mathbf{s}_k, \mathbf{s}_{k-1}) = \frac{p(\mathbf{s}_k | \mathbf{d}_1, \mathbf{d}_2, \mathbf{s}_{k-1}) p(\mathbf{d}_1, \mathbf{d}_2 | \mathbf{s}_{k-1})}{p(\mathbf{s}_k | \mathbf{s}_{k-1})}$$

其中分母 $p(\mathbf{s}_k | \mathbf{s}_{k-1})$ 独立于 $(\mathbf{d}_1, \mathbf{d}_2)$ ，因此为一个尺度常数，且可假定先验 PDF 不依赖于 \mathbf{s}_{k-1} ，即：

$$p(\mathbf{d}_1, \mathbf{d}_2 | \mathbf{s}_{k-1}) = p(\mathbf{d}_1, \mathbf{d}_2).$$

贝叶斯运动估计 (cont'd)

- **条件概率密度函数** $p(\mathbf{s}_k | \mathbf{d}_1, \mathbf{d}_2, \mathbf{s}_{k-1})$ 描述了给定参考帧 \mathbf{s}_{k-1} 和运动矢量条件下, 当前帧 \mathbf{s}_k 的分布。因此, 它可以对位移帧差(DFD)的概率分布进行建模, 可假定为一个**零均值高斯分布**:

$$p(\mathbf{s}_k | \mathbf{d}_1, \mathbf{d}_2, \mathbf{s}_{k-1}) \approx e^{-\frac{1}{2\sigma_n^2} \sum_{x_1} \sum_{x_2} [s_k(\mathbf{x}) - s_{k-1}(\mathbf{x} + \mathbf{d}(\mathbf{x}))]^2}$$

或**光流方程误差的 pdf**, 由下式给出:

$$\begin{aligned} & p(\mathbf{s}_k | \mathbf{d}_1, \mathbf{d}_2, \mathbf{s}_{k-1}) \\ & \approx e^{-\frac{1}{2\sigma_n^2} \sum_{x_1} \sum_{x_2} \left[\frac{\partial s_k(x_1, x_2)}{\partial x_1} d_1(\mathbf{x}) + \frac{\partial s_k(x_1, x_2)}{\partial x_2} d_2(\mathbf{x}) + \frac{\partial s_k(x_1, x_2)}{\partial t} \right]^2} \end{aligned}$$

贝叶斯运动估计 (cont'd)

- 运动场的先验概率密度函数 $p(\mathbf{d}_1, \mathbf{d}_2)$ 可以定义为吉布斯分布 [Gem 84]:

$$p(\mathbf{d}_1, \mathbf{d}_2) \approx e^{-\frac{\sum_{(\mathbf{x}_i, \mathbf{x}_j) \in C} \|\mathbf{d}(\mathbf{x}_i) - \mathbf{d}(\mathbf{x}_j)\|^2}{T}}$$

倾向于平滑运动场，其中 C 定义邻域系统内的两个像素团的集合， T 是温度。

- 由于对数函数是单调函数，可以对 $\ln\{p(\mathbf{s}_k | \mathbf{d}_1, \mathbf{d}_2, \mathbf{s}_{k-1}) p(\mathbf{d}_1, \mathbf{d}_2 | \mathbf{s}_{k-1})\}$ 进行最大化，或等价地，对其负值进行最小化，以寻找运动估计的最大后验概率。

则 MAP 估计 $\hat{\mathbf{d}}_1, \hat{\mathbf{d}}_2$ 是通过对下式进行最小化获得的：

$$E(\mathbf{d}_1, \mathbf{d}_2) = \frac{1}{2\sigma_n^2} \sum_{\mathbf{x}_1} \sum_{\mathbf{x}_2} [s_k(\mathbf{x}) - s_{k-1}(\mathbf{x} + \mathbf{d}(\mathbf{x}))]^2 + \frac{1}{T} \sum_{C \in C} \|\mathbf{d}(\mathbf{x}_i) - \mathbf{d}(\mathbf{x}_j)\|^2$$

- 该能量函数类似于在 Horn-Schunck 方法中使用的能量函数，因为它们都包含数据一致性项和平滑项。